UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

Ingeniería en Tecnologías de la Información e Innovación Digital

Fundamentos de Inteligencia Artificial · 7.º cuatrimestre

Clasificación de tumores de mama mediante aprendizaje automático supervisado

Informe metodológico — Actividad 3.2.1

Sistema educativo desarrollado con Python, scikit-learn y Streamlit

Integrantes del equipo

• Bernal Nájera Alexandra

• Luis Antonio Román Rey

• Fernando Yair Sanvicente Valencia

• Melonie Suárez

Docente: Mtro. Javier García Lara

Periodo: noviembre de 2026

Nota: herramienta demostrativa y educativa; no es un producto sanitario ni sustituye la evaluación de profesionales de la salud.

Resumen ejecutivo

El proyecto desarrolla un clasificador binario de carácter educativo que utiliza diez características numéricas de los núcleos celulares obtenidas del conjunto Breast Cancer Wisconsin (Diagnostic). El propósito es demostrar un flujo completo de aprendizaje automático supervisado, desde el análisis de datos hasta su integración en una aplicación web.

Se utilizaron 569 registros; 455 formaron el conjunto de entrenamiento y 114 se reservaron para prueba. Se compararon KNN, SVM, Random Forest y Árbol de Decisión mediante búsqueda de hiperparámetros y validación cruzada. El modelo elegido fue SVM con kernel RBF: accuracy = 0.9737, precision = 0.9756, recall = 0.9524 y F1 = 0.9639 en prueba.

Una ejecución independiente de reconstrucción del entrenamiento reprodujo estas métricas. La aplicación permite introducir diez medidas o cargar ejemplos sintéticos construidos con medianas; sus predicciones son ilustrativas y no constituyen evaluaciones médicas.

Contenido

Apartado	Páginas aproximadas
Problema, objetivos y justificación	3–4
Dataset y variables	5–6
Análisis exploratorio y preprocesamiento	7–10
Algoritmos y evaluación	11–15
Arquitectura, aplicación y pruebas	16–17
Limitaciones, ética y conclusiones	18–19
Referencias y declaración de uso de IA	20

Esta versión revisada conserva el planteamiento del equipo y añade explicaciones, evidencias de reproducibilidad, guía de uso y precisiones sobre las limitaciones.

1. Planteamiento del problema

Los clasificadores de aprendizaje automático pueden aprender a reconocer patrones estadísticos en muestras previamente etiquetadas. En el caso de conjuntos de datos de núcleos celulares, las mediciones cuantitativas permiten realizar ejercicios de clasificación binaria.

La problemática académica consiste en construir y evaluar un sistema capaz de asignar una etiqueta a un nuevo vector de diez medidas, sin recurrir a reglas manuales. El reto incluye evitar errores de preprocesamiento, comparar múltiples modelos, seleccionar un criterio apropiado y documentar las limitaciones.

1.1 Justificación

El proyecto resulta adecuado para demostrar una aplicación real de técnicas de aprendizaje supervisado: existe un dataset abierto, está documentada la variable que se desea predecir y se dispone de herramientas reproducibles. El uso de una interfaz web acerca el modelo a una experiencia comprensible para usuarios no especialistas.

1.2 Alcance

- Se estudian patrones presentes en un conjunto histórico de datos publicado para investigación y enseñanza.
- Se comparan cuatro algoritmos supervisados usando el mismo conjunto de entrenamiento y prueba.
- La aplicación permite probar entradas numéricas y observar la categoría estimada.
- No se proporciona ni se pretende proporcionar diagnóstico, orientación clínica ni evaluación de riesgo individual.

2. Objetivos e hipótesis de trabajo

2.1 Objetivo general

Diseñar, implementar, comparar y documentar un sistema educativo de clasificación binaria mediante aprendizaje automático supervisado, integrando el modelo seleccionado en una aplicación web reproducible.

2.2 Objetivos específicos

1. Identificar una fuente de datos abierta y describir variables de entrada y salida.
2. Examinar registros, valores faltantes, duplicados, distribuciones, correlaciones y valores atípicos.
3. Construir una separación apropiada entre datos de entrenamiento y prueba, evitando fuga de información.
4. Entrenar KNN, SVM, Random Forest y Árbol de Decisión, optimizando hiperparámetros.
5. Evaluar resultados mediante accuracy, precision, recall, F1 y ROC AUC.
6. Construir una aplicación Streamlit y documentar su ejecución y limitaciones.

2.3 Criterios de éxito

El éxito no significa obtener una clasificación clínicamente válida: significa demostrar reproducibilidad, métricas interpretables, comparación entre modelos y funcionamiento técnico de la interfaz, cumpliendo los requisitos de la actividad.

3. Ficha técnica del conjunto de datos

Elemento	Descripción
Nombre	Breast Cancer Wisconsin (Diagnostic)
Fuente	UCI Machine Learning Repository; distribuido también mediante sklearn.datasets.load_breast_cancer
Registros	569
Casos de clase 0	357 benignos
Casos de clase 1	212 malignos
Variables originales	30 características numéricas
Variables seleccionadas	10 características etiquetadas como mean
Variable objetivo	diagnosis: 0 benigno, 1 maligno (etiqueta invertida de la codificación de scikit-learn)
Tarea	Clasificación supervisada binaria
Enlace fuente	https://doi.org/10.24432/C5DW2B

Las diez características corresponden a magnitudes obtenidas de la imagen digitalizada de aspiraciones con aguja fina (FNA). El archivo original distribuido por scikit-learn ofrece 30 columnas predictoras; se seleccionaron diez para facilitar su entrada y mantener una aplicación compacta.

La selección de diez variables no elimina por completo la correlación entre ellas. Para un análisis más avanzado podría compararse con el conjunto completo de treinta y/o aplicar selección automática de características dentro de la validación cruzada.

3.1 Diccionario de variables

Variable original	Nombre en aplicación	Interpretación general
mean radius	Radio medio	Distancia media desde el centro a puntos del contorno
mean texture	Textura media	Variación de intensidad en la imagen
mean perimeter	Perímetro medio	Longitud aproximada del contorno
mean area	Área media	Área aproximada del núcleo
mean smoothness	Suavidad media	Variación local en longitudes del radio
mean compactness	Compacidad media	Relación basada en perímetro y área
mean concavity	Concavidad media	Severidad de las concavidades del contorno
mean concave points	Puntos cóncavos medios	Número relativo de porciones cóncavas
mean symmetry	Simetría media	Medida geométrica de simetría
mean fractal dimension	Dimensión fractal media	Medida de complejidad del contorno

Todas son variables numéricas. La predicción es una categoría: benigno (0) o maligno (1). Las denominaciones son estadísticas del dataset y no describen directamente la situación clínica de una persona.

4. Análisis exploratorio de datos

4.1 Integridad y distribución

La revisión del dataset mediante Pandas indica que no hay datos faltantes en las diez características elegidas ni filas duplicadas. No fue necesario imputar nulos ni codificar categorías de entrada.

Las clases no están equilibradas exactamente: 357 registros benignos (62.7 %) y 212 malignos (37.3 %). Esto justifica el uso de una división estratificada y métricas sensibles a los errores por clase, además de accuracy.

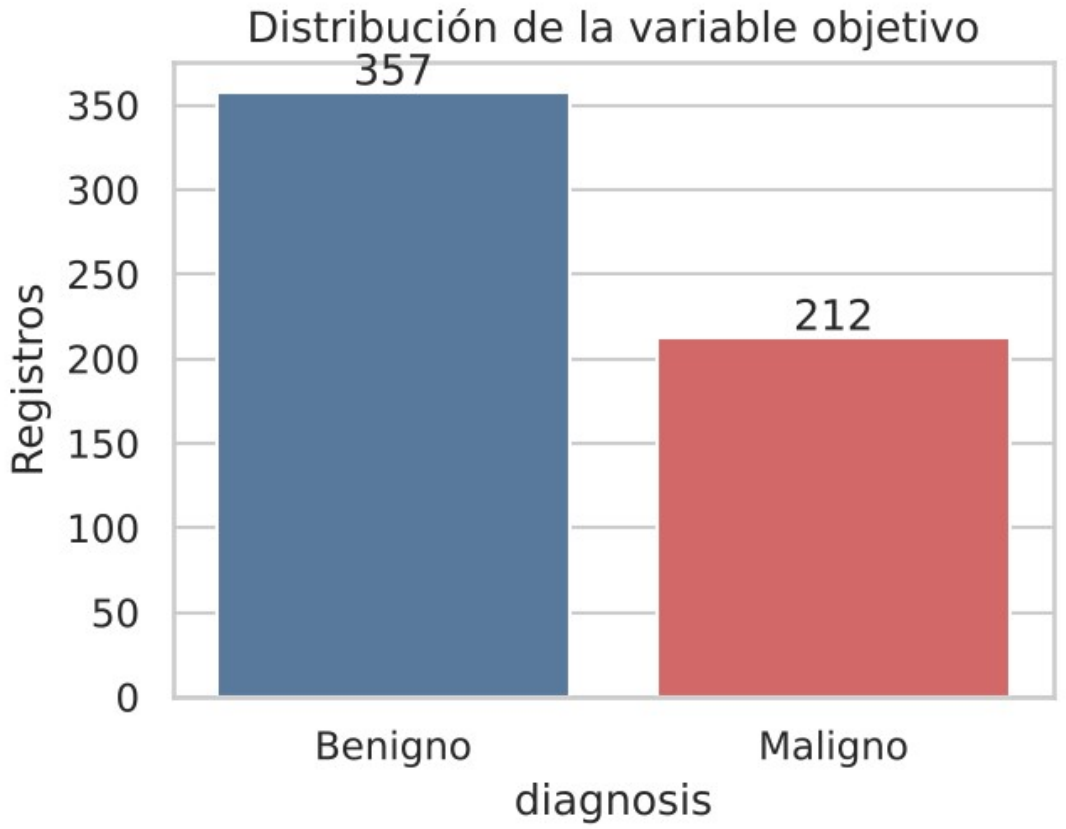


Figura 1. Cantidad de registros por clase. Fuente: análisis previo del equipo.

La diferencia entre clases no obliga por sí sola a un balanceo sintético: se decidió conservar la distribución y evaluar precision, recall y F1 por clase.

4.2 Distribuciones y relaciones entre variables

Los histogramas muestran que las variables presentan escalas y formas distintas. Algunas características de tamaño, especialmente radio, perímetro y área, exhiben distribuciones superpuestas entre ambas clases, aunque con desplazamientos en sus valores.

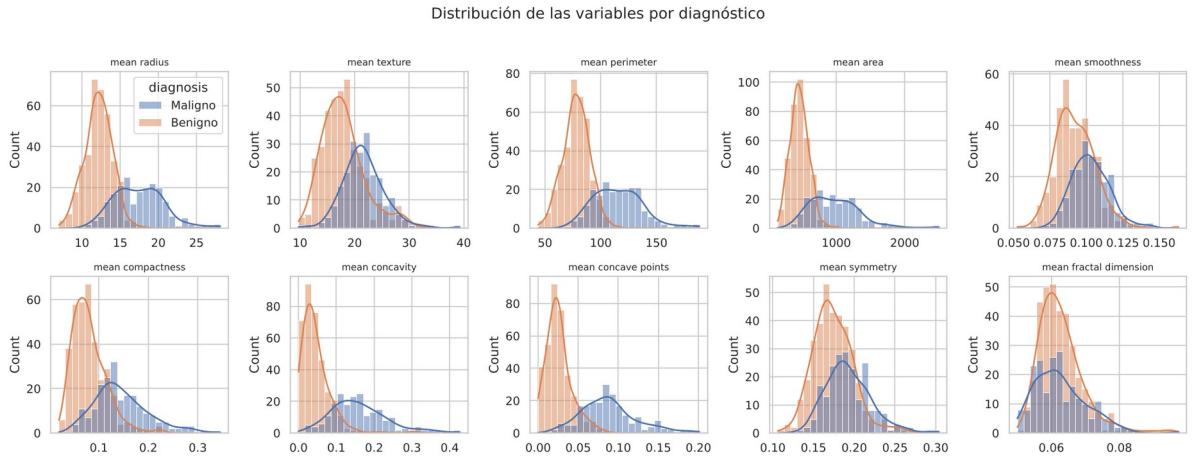


Figura 2. Distribución de características por diagnóstico, reproducida del avance del equipo.

La matriz de correlación permite observar dependencias fuertes entre algunas variables. Esto motiva el uso de modelos capaces de manejar relaciones entre características y obliga a interpretar con cautela la importancia de cada variable por separado.

4.3 Correlaciones y valores atípicos

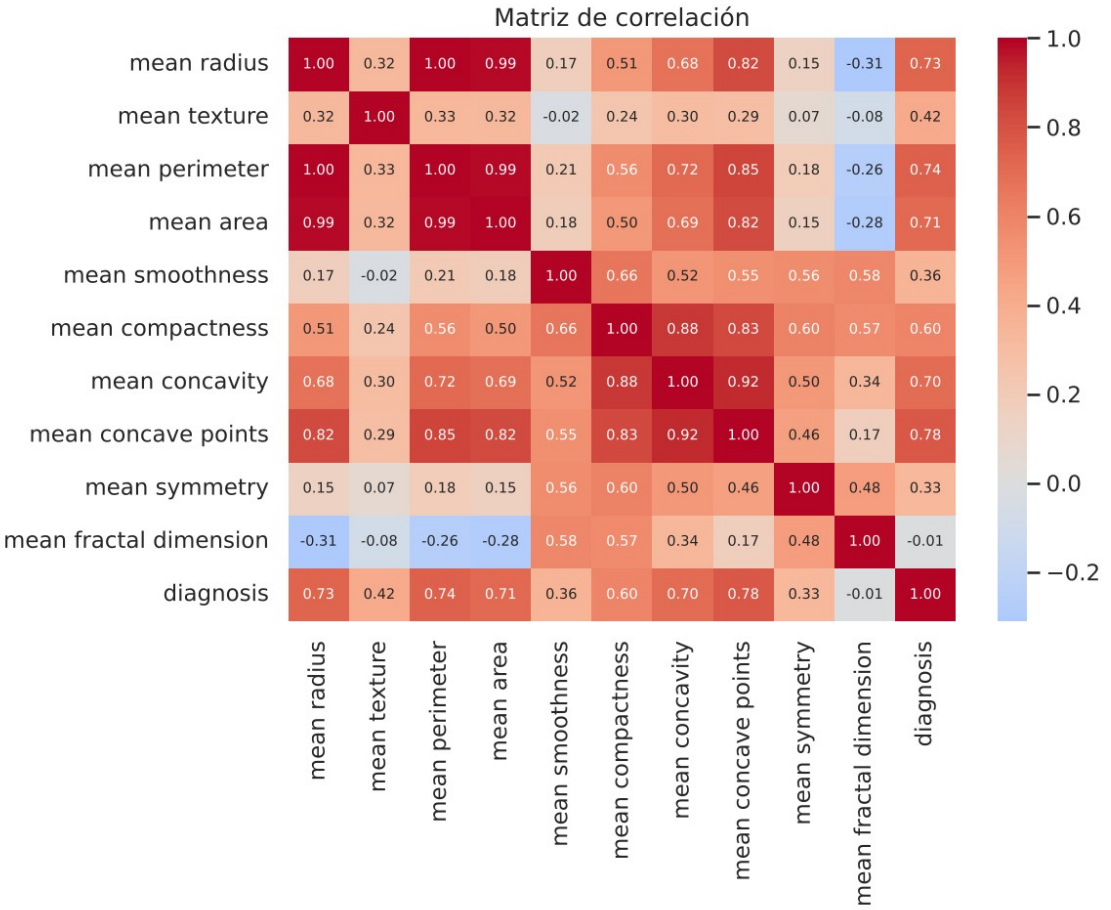


Figura 3. Correlaciones de las diez variables y la etiqueta de salida.

La relación entre radio, perímetro y área es elevada. La correlación no implica causalidad ni indica que una variable determine por sí misma la etiqueta. En este dataset se mantienen las diez variables para preservar el diseño de la aplicación.

Valores atípicos

La exploración mediante rangos intercuartílicos (IQR) detectó valores extremos en algunas variables; el avance original informa hasta 4.4 % para el área media. No se eliminaron automáticamente, ya que podrían reflejar observaciones válidas de la fuente de datos. Su conservación también evita alterar los datos sin una justificación sólida.

5. Preparación de los datos

7. Seleccionar las diez columnas de características medias; mantener la etiqueta objetivo por separado.
8. Invertir la etiqueta de salida de la versión de scikit-learn para que 1 represente la clase maligna.
9. Aplicar train_test_split con test_size = 0.20, stratify = y y random_state = 42.
10. Usar 455 registros para entrenar y 114 para evaluar una sola vez el rendimiento final.
11. Incluir StandardScaler dentro de un Pipeline para SVM y KNN, ajustándolo solo en los pliegues de entrenamiento durante la validación.
12. Conservar los valores atípicos y evitar usar las etiquetas del conjunto de prueba para tomar decisiones de ajuste.

5.1 Prevención de fuga de información

La fuga ocurre cuando parte de la información de prueba influye en el entrenamiento. Por ello, la escala de KNN y SVM no se ajusta sobre todo el dataset: el pipeline aprende media y desviación dentro de cada partición de entrenamiento. En la aplicación, el pipeline guardado aplica exactamente la transformación aprendida.

5.2 Reproducibilidad

La semilla random_state = 42 mantiene fija la división de registros. Se adjunta el script entrenar_modelos.py, el cuaderno actividad_3_2_1.ipynb, los archivos CSV de métricas y el modelo joblib correspondiente a scikit-learn 1.8.0.

6. Algoritmos comparados

K-Nearest Neighbors (KNN)

Predice según la clase de los vecinos más cercanos en el espacio de características. Su comportamiento depende de k, la medida de distancia y la escala; por ello se usa StandardScaler en el pipeline.

Support Vector Machine (SVM)

Busca una frontera de separación con buen margen entre clases. Se emplea un kernel radial RBF para capturar separaciones no lineales. Los hiperparámetros C y gamma controlan flexibilidad y regularización.

Random Forest

Combina numerosos árboles de decisión entrenados con aleatorización. Cada árbol emite una clasificación y el bosque combina sus resultados. Tiende a ser robusto, aunque la interpretación directa es menos simple que la de un árbol individual.

Árbol de Decisión

Construye reglas sucesivas sobre las características. Es fácil de explicar, pero puede sobreajustarse si crece sin límites. Por esa razón se probaron restricciones de profundidad y de cantidad mínima de ejemplos en hojas.

7. Entrenamiento y optimización

Cada algoritmo se entrenó mediante GridSearchCV con cinco pliegues de validación cruzada estratificada, usando F1 como objetivo. Las búsquedas se ejecutaron exclusivamente sobre los 455 registros de entrenamiento.

Algoritmo	Hiperparámetros analizados
SVM	C: 0.1, 1, 10, 100; gamma: scale, 0.001, 0.01, 0.1; kernel RBF
KNN	k: 3, 5, 7, 9, 11; pesos uniformes o por distancia
Random Forest	100 o 200 árboles; profundidad None, 5 o 10; mínimo en hoja 1 o 2
Árbol de Decisión	Profundidad None, 3, 5 o 7; mínimo en hoja 1, 2 o 4; criterio gini o entropía

7.1 Configuración ganadora del clasificador final

El mejor SVM encontrado en la búsqueda tiene C = 100, gamma = 0.01 y kernel = RBF. Está almacenado dentro de un Pipeline con StandardScaler. El archivo modelo.joblib fue generado a partir del código reproducible incluido en esta entrega.

No basta comparar accuracy: en la clase positiva de interés se debe observar particularmente recall, precision y F1. Además, el modelo seleccionado se evaluó sobre el conjunto de prueba que no participó en su ajuste.

8. Resultados en el conjunto de prueba

La tabla presenta la reconstrucción reproducible de los resultados, redondeada a tres decimales. Se corrigió el ROC AUC de Random Forest a 0.985, coherente con el valor no redondeado 0.9848.

Modelo	Accuracy	Precision	Recall	F1	ROC AUC
SVM	0.974	0.976	0.952	0.964	0.989
KNN	0.947	0.909	0.952	0.930	0.975
Random Forest	0.939	0.927	0.905	0.916	0.985
Árbol de Decisión	0.921	0.923	0.857	0.889	0.928

8.1 Qué significa cada indicador

- Accuracy: proporción total de registros clasificados correctamente.
- Precision de la clase maligna: fracción de predicciones malignas que corresponden a esa clase.
- Recall: proporción de los registros malignos que el clasificador identifica como tales.
- F1: media armónica de precision y recall; resume su equilibrio.
- ROC AUC: capacidad de ordenamiento entre clases al variar el umbral.

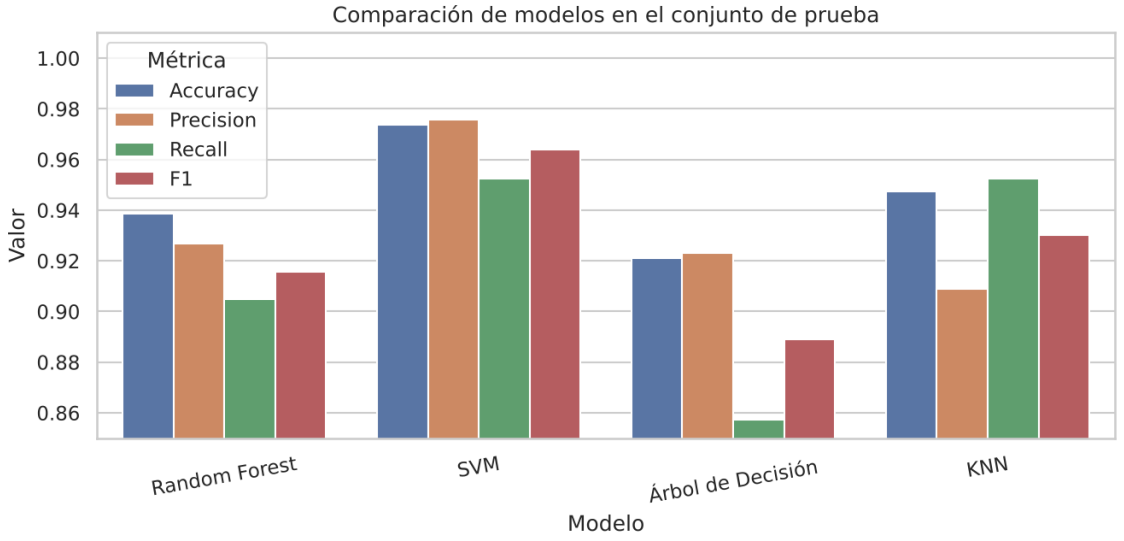


Figura 4. Comparación de métricas mostrada en el informe original.

8.2 Selección y validación repetida

Dado que las diferencias entre modelos son pequeñas, se volvió a valorar cada configuración optimizada con validación cruzada estratificada de cinco pliegues y tres repeticiones, solo en los registros de entrenamiento.

Modelo	F1 medio	Desv. estándar F1	Recall medio
SVM	0.9198	0.0302	0.9039
Random Forest	0.9196	0.0369	0.9098
KNN	0.9135	0.0359	0.8961
Árbol de Decisión	0.9094	0.0487	0.9059

La diferencia de 0.0002 entre F1 de SVM y Random Forest es mínima, por lo que no permite asegurar superioridad general del primero. Se seleccionó SVM por su rendimiento en prueba y la estabilidad observada, evitando afirmar que el resultado se extrapola a cualquier otro conjunto.

8.3 Advertencia sobre la selección de modelos

La optimización y la comparación se realizaron en datos de entrenamiento. La repetición usa hiperparámetros previamente seleccionados; no es una validación cruzada anidada. Esto puede producir estimaciones algo optimistas. Un estudio más exigente usaría validación anidada y datos externos.

8.4 Matriz de confusión y errores

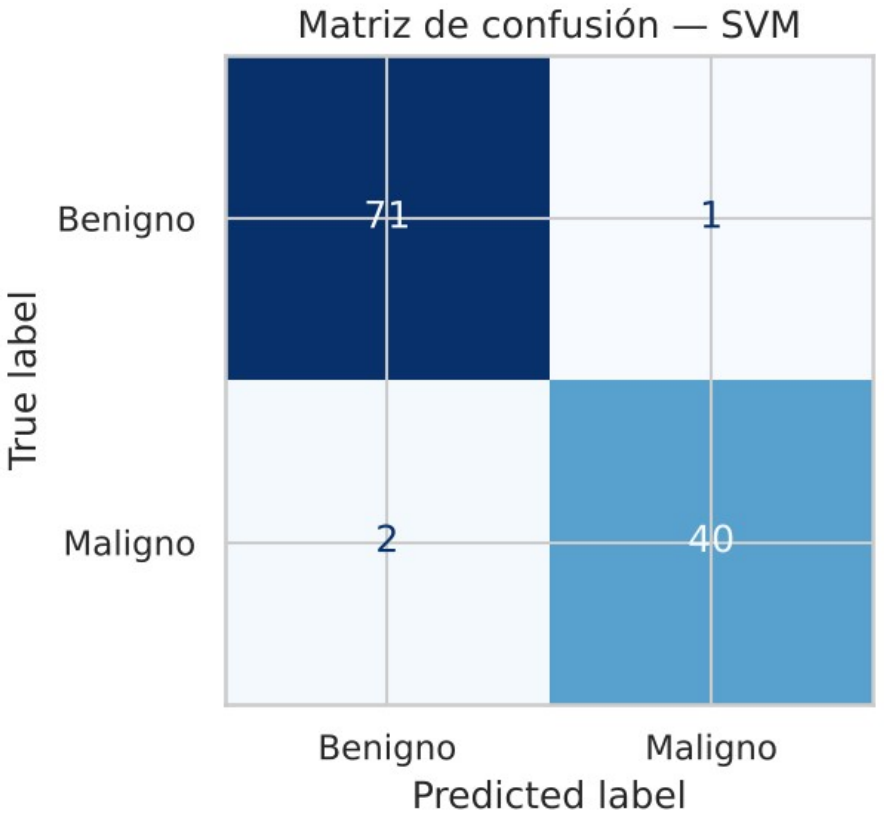


Figura 5. Matriz de confusión del SVM con 114 registros de prueba.

En las 114 observaciones se registraron 71 verdaderos negativos, 40 verdaderos positivos, un falso positivo y dos falsos negativos. El modelo detectó 40 de los 42 casos de la clase maligna en el conjunto de prueba.

El recall = 40 / 42 ≈ 0.9524 y precision = 40 / 41 ≈ 0.9756. Cada caso de la clase maligna equivale aproximadamente a 2.38 puntos porcentuales de recall, por lo que las métricas tienen incertidumbre notable en una muestra pequeña.

Los falsos negativos merecen atención al analizar errores del clasificador, pero los resultados no deben interpretarse como desempeño clínico. La revisión se limita a etiquetas de datos de investigación.

9. Arquitectura de la aplicación

Componente	Función
Interfaz Streamlit	Solicita los diez valores o carga medianas sintéticas; presenta avisos educativos.
app.py	Valida entradas, organiza las características y consulta el modelo guardado.
models/modelo.joblib	Pipeline que contiene StandardScaler y SVM entrenado.
models/metadata.json	Orden de variables, rangos de entrenamiento y métricas de prueba.
data/breast_cancer_wisconsin.csv	Datos para ejemplos sintéticos, sin información personal adicional.
README.md	Instrucciones de instalación, uso y reproducibilidad.

9.1 Flujo de predicción

Usuario → selección de ejemplo o introducción de diez medidas → verificación de rangos → construcción de DataFrame con columnas ordenadas → modelo Pipeline (escalado y SVM) → etiqueta y puntaje estimado → advertencia sobre alcance educativo.

9.2 Tecnologías

- Python: lenguaje principal.
- Pandas: carga y organización de datos.
- Scikit-learn: entrenamiento, validación y pipeline.
- Joblib: serialización del modelo.
- Streamlit: interfaz web accesible desde un navegador.

La aplicación web no es un APK. La consigna acepta explícitamente proyectos Streamlit o Gradio, por lo que no se requiere empaquetar una aplicación de Android.

10. Uso y pruebas de la aplicación

El usuario puede escoger un conjunto de medianas de los registros (ejemplo sintético), escribir valores manualmente y pulsar Predecir. El sistema muestra la clase estimada y el puntaje asociado, aclarando que no representa una probabilidad clínica.

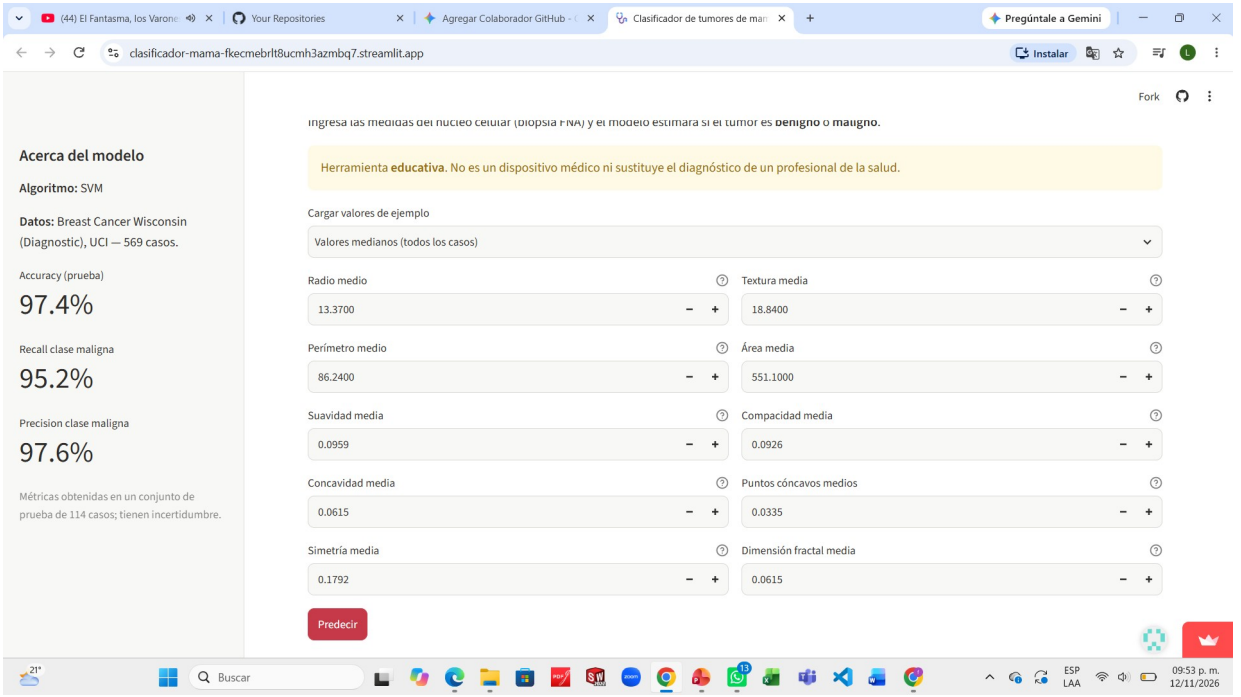


Figura 6. Captura de la aplicación previa, proporcionada por el equipo.

10.1 Casos de prueba sugeridos

Prueba	Resultado esperado
Abrir la página	Se muestran título, advertencia, diez campos y métricas.
Cargar medianas benignas	Se actualizan los diez valores.
Cargar medianas malignas	Se actualizan los diez valores.
Introducir un valor fuera del rango	Aparece aviso de extrapolación.
Pulsar Predecir	Se muestra etiqueta y puntaje del modelo.

11. Limitaciones, riesgos y ética

Limitaciones técnicas

- El conjunto de datos solo contiene 569 registros de una fuente histórica.
- Las 114 observaciones de prueba representan una muestra limitada.
- Los ejemplos basados en medianas son combinaciones sintéticas; no equivalen a registros clínicos reales.
- La diferencia entre SVM y Random Forest en validación repetida es mínima.
- Las probabilidades reportadas por el modelo no garantizan calibración adecuada para otros contextos.
- No existe validación clínica, prospectiva ni con datos de otras instituciones.

Consideraciones éticas

No se deben utilizar las predicciones para diagnosticar, descartar enfermedades, decidir tratamientos ni tranquilizar o alarmar a una persona. El sistema debe mostrar claramente que se trata de una práctica académica. Los usuarios no deben cargar información identificable ni registrar datos de salud personales en el repositorio.

Honestidad y transparencia

Se incluyen la fuente, las métricas, los errores y los algoritmos evaluados. Asimismo, se declaran las herramientas de IA generativa utilizadas como apoyo. Todo resultado debe poder rastrearse al código y los archivos de la entrega.

12. Conclusiones y mejoras futuras

El ejercicio demuestra cómo un algoritmo de aprendizaje supervisado puede aprender patrones a partir de datos etiquetados y producir una clasificación para nuevas entradas. Se implementó el ciclo de selección de datos, exploración, preparación, entrenamiento, evaluación y despliegue.

En el conjunto de prueba, el SVM obtuvo accuracy de 97.4 % y recall de 95.2 % para la clase maligna. Estas cifras son suficientes para ilustrar las métricas y el funcionamiento de una app académica, pero no se extrapolan a pacientes, hospitales ni decisiones de salud.

Mejoras futuras

13. Comparar la versión de diez características con las treinta variables originales.
14. Incorporar validación cruzada anidada y evaluar la estabilidad de los hiperparámetros.
15. Investigar métodos de calibración del puntaje, sin interpretarlo clínicamente.
16. Diseñar pruebas automatizadas y monitorear compatibilidad de las dependencias.
17. Mejorar accesibilidad y documentación de la interfaz para usuarios principiantes.

Contribución académica

El principal resultado es una solución reproducible y explicable, no una herramienta de salud. El equipo puede demostrar, con el notebook y el sitio web, cómo se conectan los datos, los algoritmos y las predicciones.

Referencias bibliográficas (APA 7)

Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32. https://doi.org/10.1023/A:1010933404324

Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273–297. https://doi.org/10.1007/BF00994018

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Streamlit. (s. f.). Streamlit documentation. https://docs.streamlit.io/

Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1995). Breast Cancer Wisconsin (Diagnostic) [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B

Declaración de uso de inteligencia artificial

De acuerdo con el avance inicial, el equipo utilizó Claude (Anthropic) como apoyo en la estructura del proyecto, borradores de código y redacción. En la revisión posterior se utilizó ChatGPT (OpenAI, GPT-6, 2026) para analizar la consigna, reconstruir y probar el entrenamiento, revisar la aplicación y ampliar la documentación. El equipo debe verificar las afirmaciones, ejecutar el código y comprender los resultados antes de su entrega.

Material complementario

Repositorio del equipo: https://github.com/lexanajera0306-boop/clasificador-mama

Aplicación publicada originalmente: https://clasificador-mama-fkecmebrlt8ucmh3azmbq7.streamlit.app/

Esta versión revisada no actualiza automáticamente el repositorio ni el despliegue. Deben subirse los nuevos archivos y comprobarse el sitio tras publicarlos.