UNIVERSIDAD POLITÉCNICA DE ATLAUTLA · ACTIVIDAD 3.2.1

Clasificador de muestras de mama

Aprendizaje automático supervisado

Una aplicación educativa que compara cuatro algoritmos y utiliza SVM para clasificar registros de investigación.



Equipo

Bernal Nájera Alexandra · Luis Antonio Román Rey
Fernando Yair Sanvicente Valencia · Melonie Suárez

Asignatura: Fundamentos de Inteligencia Artificial · 7.º cuatrimestre

¿Qué problema resolvemos?

Una clasificación binaria a partir de datos de investigación.

Pregunta del proyecto

¿Puede un modelo identificar patrones en diez medidas numéricas para distinguir registros etiquetados como benignos o malignos?

Objetivo

Construir, comparar y desplegar un sistema de clasificación supervisada que pueda probarse en una página web.

El propósito es académico: estudiar patrones estadísticos, no realizar diagnósticos médicos.

Dataset: 569 registros etiquetados

Breast Cancer Wisconsin (Diagnostic) · UCI Machine Learning Repository

569	10	455	114
Registros	Variables utilizadas	Entrenamiento	Prueba

Distribución de las clases



357 benignos · 62.7 %

212 malignos · 37.3 %

Entradas

Radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal.

Fuente: UCI · doi.org/10.24432/C5DW2B

Del dato a la aplicación

Separamos entrenamiento y prueba antes de ajustar los modelos.

01

Explorar

Revisar nulos, duplicados y atípicos

02

Preparar

Elegir las 10 variables y dividir 80/20

03

Entrenar

Optimizar 4 algoritmos con validación cruzada

04

Evaluar

Medir accuracy, precision, recall y F1

05

Publicar

Guardar SVM y probarlo con Streamlit

Sin fuga de información StandardScaler se ajusta dentro del Pipeline usando solo datos de entrenamiento.

Probamos cuatro algoritmos

Todos se evaluaron con los mismos registros de prueba.

KNN

Clasifica de acuerdo con los vecinos más cercanos a cada registro.

SVM

Busca una frontera que separe las clases; usa kernel RBF para patrones no lineales.

Random Forest

Combina las decisiones de varios árboles para producir una clasificación.

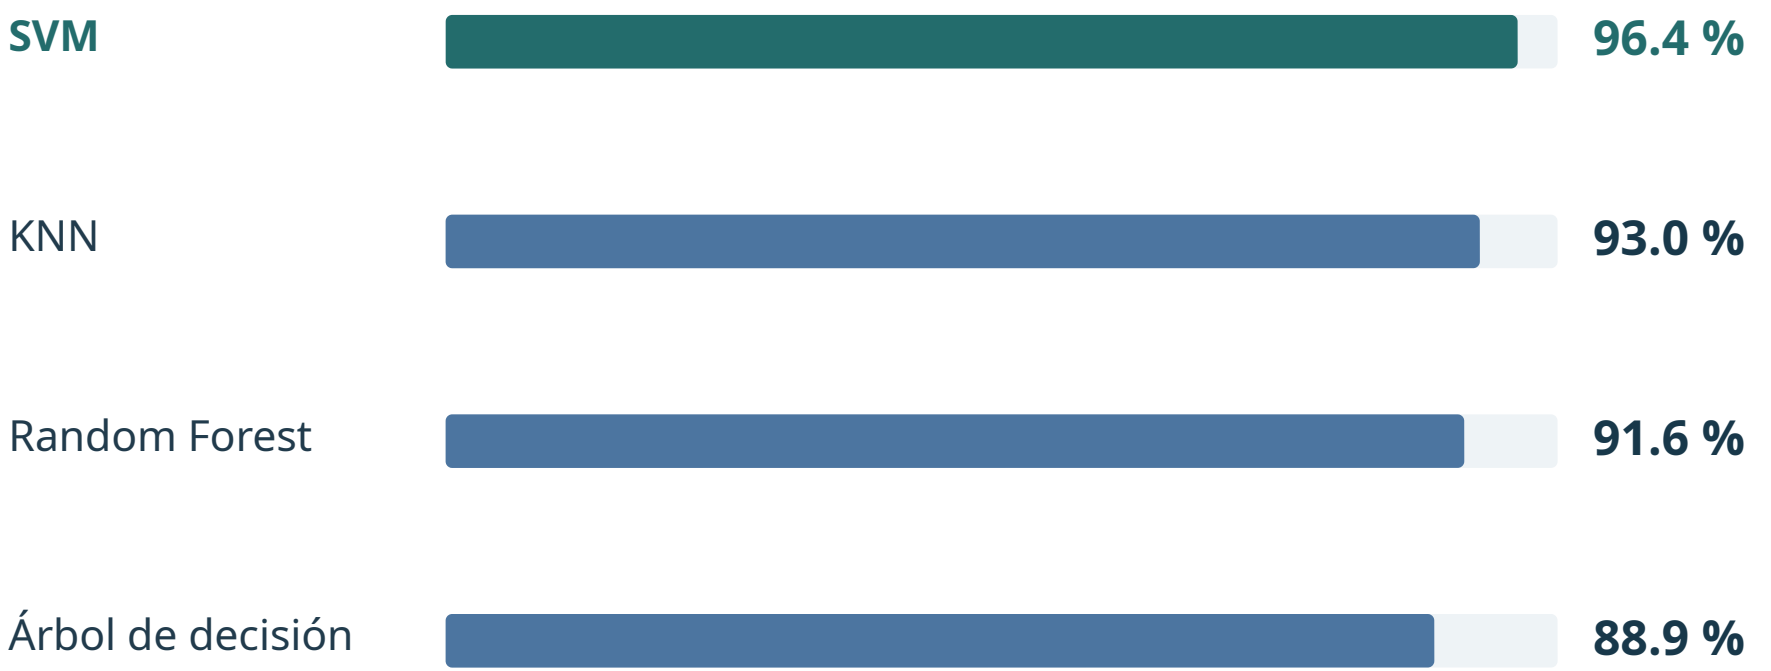
Árbol de decisión

Construye reglas sucesivas con preguntas sobre las variables.

Ajuste de hiperparámetros: GridSearchCV · validación cruzada estratificada de 5 pliegues.

Comparación de los cuatro modelos

F1 en el conjunto de prueba · escala completa de 0 a 1.



Modelo elegido

SVM

97.4 %

Accuracy

En validación repetida, SVM y Random Forest estuvieron casi empatados (F1: 0.9198 vs. 0.9196).

¿Cómo funciona el SVM que elegimos?

Modelo: Support Vector Machine con kernel RBF.

1 · Entrada

Recibe las 10 mediciones numéricas

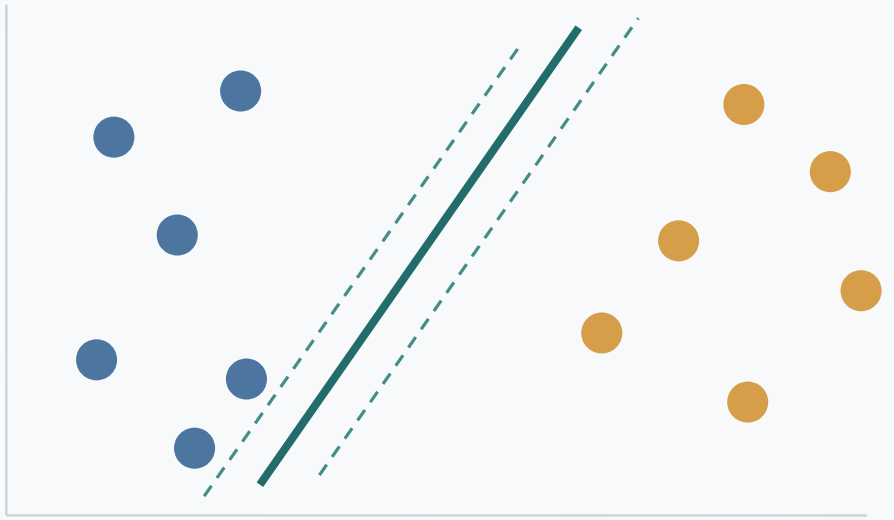
2 · Escala

StandardScaler normaliza las magnitudes

3 · Clasifica

La frontera del SVM asigna una clase

Frontera de separación · esquema conceptual



Parámetros del modelo final: kernel RBF · C = 100 · gamma = 0.01

¿Qué tan bien funcionó el SVM?

Resultados sobre 114 registros que no participaron en el entrenamiento.

97.4 %

Accuracy

95.2 %

Recall (maligno)

40 de 42

registros malignos identificados correctamente

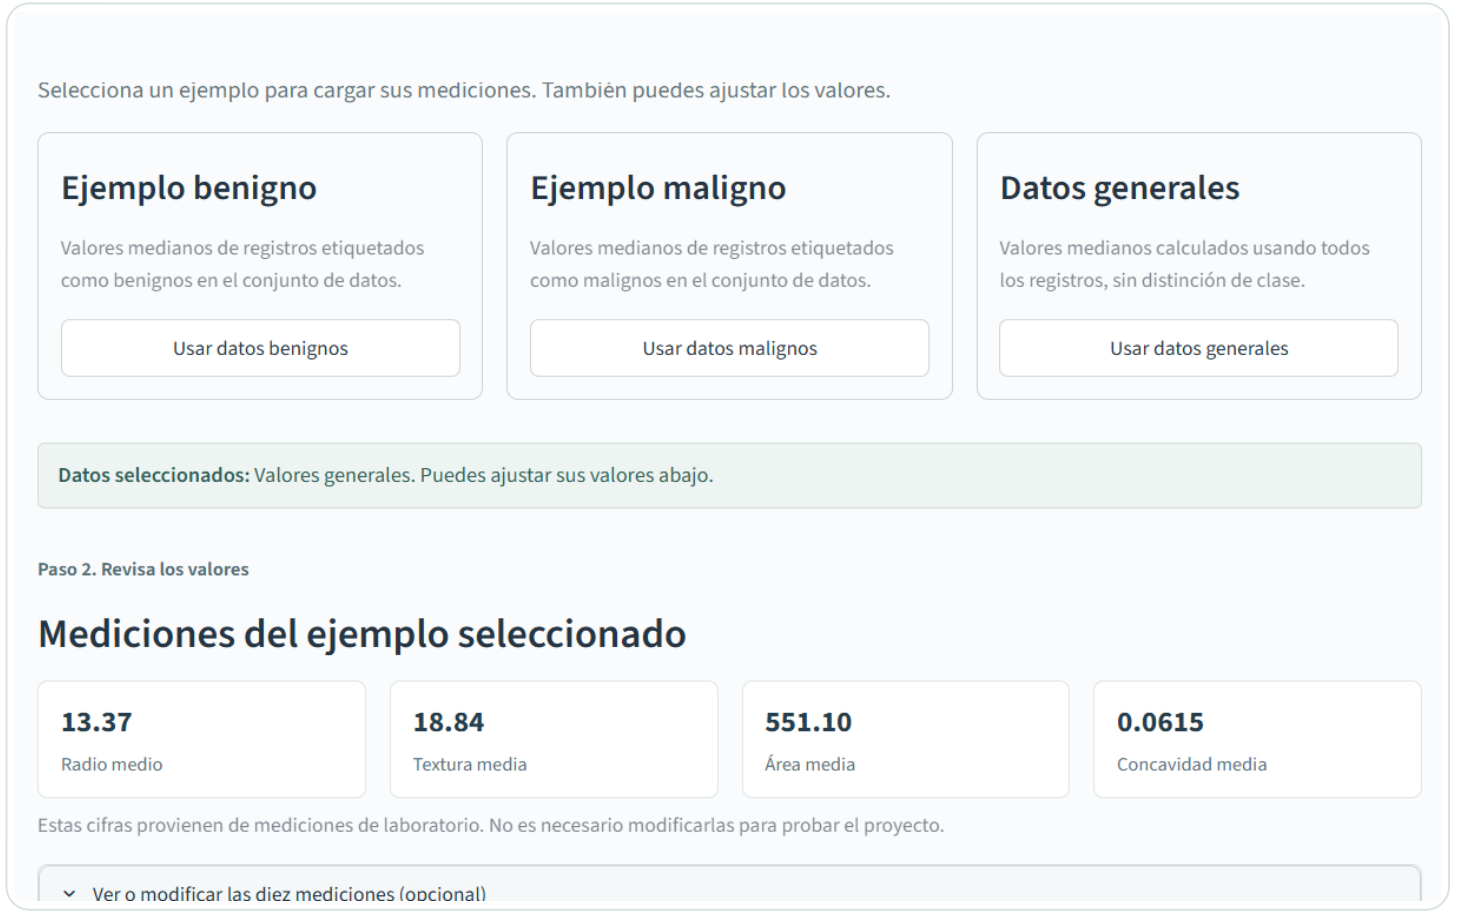
3 errores en total: 1 falso positivo y 2 falsos negativos.

Matriz de confusión

REAL \ PREDICCIÓN	Benigno	Maligno
Benigno	71	1
Maligno	2	40

Así se utiliza la aplicación

Interfaz web construida con Streamlit · disponible en el enlace del proyecto.



Captura de la aplicación definitiva del equipo.

1 Elegir datos

Ejemplo benigno, maligno o general

2 Revisar medidas

Diez valores; la edición es opcional

3 Calcular

Obtener una categoría ilustrativa

Del ejemplo al resultado

Captura real de la clasificación con valores generales del conjunto.



Resultado visible

BENIGNO

Ejemplo mostrado

Salida numérica de la clase maligna: 9.4 %

Es una salida del algoritmo, no una probabilidad clínica.

Demostración en vivo: 30–40 s; si falla la conexión, usar esta captura.

Lo que el sistema puede y no puede hacer

Una evaluación técnica no equivale a una validación clínica.

Sí demuestra

Un flujo reproducible con datos abiertos, comparación de modelos, métricas y una interfaz funcional.

No demuestra

Que el modelo sea apto para diagnosticar, descartar enfermedades o evaluar a personas concretas.

Limitaciones del estudio 569 registros de una sola fuente, 114 en prueba y diferencias pequeñas entre SVM y Random Forest.

Una solución reproducible y funcional

La evidencia central: datos documentados, cuatro modelos y un clasificador web.

Conclusión

Seleccionamos SVM porque ofreció el mejor equilibrio observado en la prueba y un comportamiento estable en validación.

¿Qué entregamos?

Aplicación Streamlit · Notebook y código · Informe metodológico · Repositorio GitHub

Prueba la aplicación

clasificador-mama-equipo-ia.streamlit.app

Fuentes: UCI (Breast Cancer Wisconsin, doi:10.24432/C5DW2B); Pedregosa et al. (2011); documentación de Streamlit.
Código del equipo: github.com/lexanajera0306-boop/Actividad_3_2_1-AprendizajeAutomaticoSupervisado-