Clasificación de tumores de mama

con aprendizaje automático supervisado

Actividad 3.2.1 · Fundamentos de Inteligencia Artificial
Ingeniería en Tecnologías de la Información e Innovación Digital · 7.° cuatrimestre

Equipo
Bernal Nájera Alexandra
Luis Antonio Román Rey
Fernando Yair Sanvicente Valencia
Melonie Suárez

El problema: detectar tumores malignos a tiempo

569
registros de biopsias (FNA)

10
variables del núcleo celular

37 %
de los casos son malignos

- Objetivo: predecir si un tumor es benigno o maligno (clasificación binaria).
- Datos: Breast Cancer Wisconsin (Diagnostic), UCI.
- Métrica prioritaria: Recall de la clase maligna; un falso negativo es el error más costoso.

Análisis y preparación de los datos

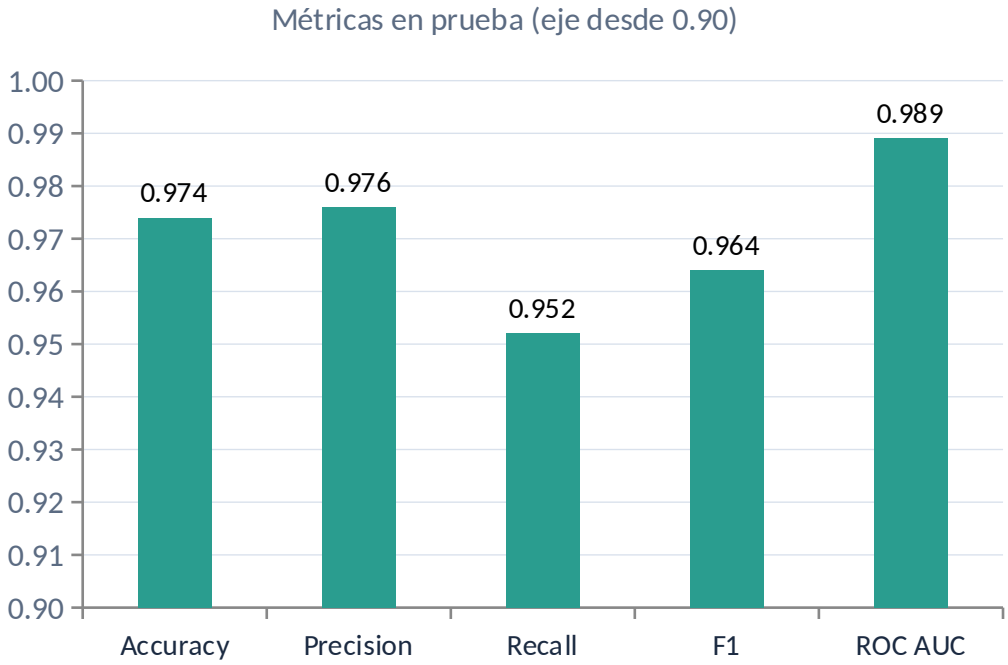
- Calidad: sin valores faltantes ni duplicados; todas las variables son numéricas.
- Clases moderadamente desbalanceadas (63 % benigno / 37 % maligno): partición estratificada.
- Atípicos detectados con IQR (hasta 4.4 %): son tumores grandes reales, por eso se conservan.
- Área, radio y perímetro están casi perfectamente correlacionados; se usan solo las 10 variables "media".
- Partición 80/20 (455 entrenamiento, 114 prueba) y StandardScaler dentro de un Pipeline, sin fuga de datos.

Cuatro modelos comparados

Modelo	Accuracy	Precision	Recall	F1	ROC AUC
SVM	**0.974**	**0.976**	**0.952**	**0.964**	**0.989**
KNN	0.947	0.909	0.952	0.930	0.975
Random Forest	0.939	0.927	0.905	0.916	0.985
Árbol de Decisión	0.921	0.923	0.857	0.889	0.928

Resultados en el conjunto de prueba (114 casos). Cada modelo se optimizó con GridSearchCV (5 pliegues).
El ganador se eligió con validación cruzada repetida (5 × 3) sobre entrenamiento; SVM y Random Forest quedaron casi empatados.

Modelo ganador: SVM



40 de 42

tumores malignos detectados

3 errores

1 falso positivo y 2 falsos negativos

Hiperparámetros: C = 100, gamma = 0.01, kernel RBF.

Aplicación web funcional

- Construida con Streamlit; el modelo se carga desde un archivo joblib.
- El usuario ingresa las 10 medidas o carga un ejemplo.
- Devuelve la clase (benigno o maligno) y su probabilidad.
- Avisa si un dato está fuera del rango de entrenamiento y declara su uso educativo.

Pruébala en tu celular

Aplicación en línea
clasificador-mama-fkecmebrlt8ucmh3azmbq7.streamlit.app

Repositorio en GitHub
github.com/lexanajera0306-boop/clasificador-mama

Limitaciones, honestidad y conclusiones

Limitaciones

- Dataset pequeño y de una sola fuente.
- Prueba de 114 casos: un caso mueve el Recall 2.4 puntos.
- SVM y Random Forest, casi empatados.
- Sin validación clínica: solo uso educativo.

Conclusiones

- Con solo 10 variables, los cuatro modelos rinden bien; SVM equilibra mejor Precision y Recall.
- Solución reproducible: semilla fija, datos y código en GitHub.
- Uso de IA generativa declarado (Claude, Anthropic); el equipo revisó y adaptó el código.
- Siguiente paso: validar con datos externos y ajustar el umbral para maximizar el Recall.

Referencias

Wolberg, W., Mangasarian, O., Street, N. y Street, W. (1993). *Breast Cancer Wisconsin (Diagnostic)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B

Street, W. N., Wolberg, W. H. y Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *IS&T/SPIE International Symposium on Electronic Imaging*, *1905*, 861-870.

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Cortes, C. y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, *20*(3), 273-297.

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5-32.

Streamlit. (s. f.). *Streamlit documentation*. https://docs.streamlit.io

Anthropic. (2026). *Claude* [Modelo de lenguaje de gran tamaño]. https://claude.ai (apoyo declarado en el desarrollo del proyecto).